

Υλοποίηση Συστημάτων Βάσεων Δεδομένων

Εργασίες 1 & 2

Κωνσταντίνος Χούσος

AM: 1115202000215

Αναστάσιος-Φαίδων Σεϊτανίδης

AM: 1115202000179

ΕΡΓΑΣΙΑ 1

Αρχείο Σωρού

Συναρτήσεις

Οι παρακάτω συναρτήσεις εκμεταλλεύονται τις συναρτήσεις επιπέδου block **BF_*** για την υλοποίησή τους, προσθέτοντας ωστόσο παραπάνω λειτουργικότητα.

- **HP_CreateFile:** Δημιουργεί το αρχείο με όνομα **filename**, δημιουργεί το block 0 και αρχικοποιεί τις τιμές του όσον αφορά τα **HP_info** και **HP_block_info**. Κάνει το block 0 dirty και το κάνει unpin. Τέλος, κλείνει το αρχείο.
- **HP_OpenFile:** Ανοίγει το αρχείο σωρού με όνομα **filename**. Ελέγχει αν το αρχείο πρόκειται για αρχείο κατακερματισμού ή όχι. Αν όχι, συνεχίζει. Καθώς κάθε φορά που καλείται η **BF_OpenFile** το **fileDesc** αλλάζει, ενημερώνουμε κάθε φορά το **HP_info** του block 0. Κάνουμε dirty και unpin το block 0, κρατώντας ωστόσο το **HP_info** στον σωρό και επιστρέφοντάς το.
- **HP_CloseFile:** Βρίσκει πόσα blocks έχει το αρχείο σωρού. Σε ένα for loop κάνει το καθένα unpin. Κλείνει το αρχείο και αποδεσμεύει την μνήμη του **HP_info** που υπάρχει στον σωρό.
- **HP_InsertEntry:** Βρίσκει το τελευταίο block του αρχείου σωρού. Ελέγχει αν υπάρχει αρκετός χώρος σε αυτό για την εγγραφή μιας πλειάδας. Αν ναι, αντιγράφει την πλειάδα σε αυτό. Αν όχι, δημιουργεί ένα νέο block στο τέλος του αρχείου σωρού, γράφει σε αυτό την πλειάδα και αρχικοποιεί τα metadata του. Έπειτα ενημερώνει το **HP_info** για το νέο block και το κάνει unpin. Τέλος, επιστρέφει τον αναγνωριστικό αριθμό του block στο οποίο έγινε τελικά η εγγραφή.
- **HP_GetAllEntries:** Η συνάρτηση επιστρέφει μία μεταβλητή **int read_blocks**. Αυτή αρχικοποιείται με -1 και ανανεώνεται όταν βρούμε ένα record με **id = value**. Αν επιστραφεί και δεν έχει αλλάξει, σημαίνει πως υπήρξε κάποιο σφάλμα. Διατρέχει όλα τα blocks του αρχείου σωρού, βρίσκει για το καθένα πόσες εγγραφές υπάρχουν και τυπώνει αυτές που έχουν **id = value**.

Δομή Αρχείου Σωρού

- Δομή **HP_info**

Ένα αρχείο σωρού χαρακτηρίζεται από τα εξής στοιχεία:

- **int fileDesc:** Ο αναγνωριστικός αριθμός ανοίγματος αρχείου από το επίπεδο block.

- **int lastBlockDesc**: Ο αναγνωριστικός αριθμός του τελευταίου σε αριθμό block του αρχείου σωρού.
 - **int filetype**: Ένα flag που δηλώνει τον τύπο του αρχείου. Στην περίπτωση αρχείου σωρού έχει τιμή 1.
- Δομή **HP_block_info**
Ένα block ενός αρχείου σωρού χαρακτηρίζεται από τα εξής στοιχεία:
 - **int blockDesc**: Ο αναγνωριστικός αριθμός του block στην αρίθμηση των block του αρχείου σωρού.
 - **int recsNum**: Το πλήθος εγγεγραμμένων πλειάδων στο συγκεκριμένο block.
 - **int nextBlock**: Ο αναγνωριστικός αριθμός του επόμενου block στην αρίθμηση των block του αρχείου σωρού. Αν δεν υπάρχει τότε έχει την τιμή -1, με την οποία αρχικοποιείται.

Σημειώσεις

Το **HP_ERROR** ορίζεται σε -1, καθώς δεν έχει αρχικοποιηθεί κι αλλιώς δεν δουλεύει η συνάρτηση **CALL_BF**.

Αρχείο Κατακερματισμού

Συναρτήσεις

Οι παρακάτω συναρτήσεις εκμεταλλεύονται τις συναρτήσεις επιπέδου block **BF_*** για την υλοποίησή τους, προσθέτοντας ωστόσο παραπάνω λειτουργικότητα.


- **HT_CreateFile**: Δημιουργεί το αρχείο με όνομα **filename**, δημιουργεί το block 0 κι αρχικοποιεί τις τιμές του όσον αφορά τα **HT_info** και **HT_block_info**. Κάνει το block 0 dirty και το κάνει unpin. Τέλος, κλείνει το αρχείο.
- **HT_OpenFile**: Ανοίγει το αρχείο κατακερματισμού με όνομα **filename**. Ελέγχει αν το αρχείο πρόκειται για αρχείο κατακερματισμού ή όχι. Αν ναι, συνεχίζει. Αρχικοποιεί το hashtable που θα υπάρχει στην μνήμη. Καθώς κάθε φορά που καλείται η **BF_OpenFile** το **fileDesc** αλλάζει, ενημερώνουμε κάθε φορά το **HT_info** του block 0. Κάνουμε dirty κι unpin το block 0, κρατώντας ωστόσο το **HT_info** στον σωρό κι επιστρέφοντάς το.
- **HT_CloseFile**: Βρίσκει πόσα blocks έχει το αρχείο κατακερματισμού. Σε ένα for loop κάνει το καθένα unpin. Κλείνει το αρχείο κι αποδεσμεύει την μνήμη του **HT_info** που υπάρχει στον σωρό, καθώς και την μνήμη του hashtable.
- **HT_InsertEntry**: Βρίσκει τον κάδο στον οποίο πρέπει να καταγραφεί η εγγραφή. Αν ο κάδος δεν έχει κάποιο block, τότε δημιουργεί ένα και το συσχετίζει με τον κάδο μέσω του hashtable. Βρίσκουμε αν στο πιο πρόσφατο block του κάδου χωράει η εγγραφή. Αν ναι, την γράφει εκεί. Αν όχι, δημιουργεί ένα νέο block για τον κάδο—το οποίο γίνεται το πιο πρόσφατό του—και γράφει εκεί την εγγραφή.
- **HT_GetAllEntries**: Η συνάρτηση επιστρέφει μία μεταβλητή **int read_blocks**. Αυτή αρχικοποιείται με -1 και ανανεώνεται όταν βρούμε ένα record με **id == value**. Αν επιστραφεί και δεν έχει αλλάξει, σημαίνει πως υπήρξε κάποιο σφάλμα. Η συγκεκριμένη συνάρτηση βρίσκει τον κάδο που περιέχει εγγραφές με **id == value** και διατρέχει όλα τα blocks του, από το πιο πρόσφατο προς το πρώτο.

Δομή Αρχείου Κατακερματισμού

- Δομή HT_info

Ένα αρχείο κατακερματισμού χαρακτηρίζεται από τα εξής στοιχεία:

- **int fileDesc**: 0 αναγνωριστικός αριθμός ανοίγματος αρχείου από το επίπεδο block.
- **int lastBlockDesc**: 0 αναγνωριστικός αριθμός του τελευταίου σε αριθμό block του αρχείου κατακερματισμού.
- **int filetype**: Ένα flag που δηλώνει τον τύπο του αρχείου. Στην περίπτωση αρχείου κατακερματισμού έχει τιμή 2.
- **long int numBuckets**: Το πλήθος των κάδων που θα έχει το αρχείο κατακερματισμού.
- **int *hashtable**: Ένας πίνακας μεταβλητού μεγέθους σε int. Το hashtable του αρχείου κατακερματισμού αναπαριστάται ως εξής: Η κάθε θέση του πίνακα hashtable αναπαριστά έναν κάδο. Δηλαδή για παράδειγμα, το **hashtable[2]** δηλώνει τον κάδο 2. Το περιεχόμενο της κάθε θέσης όμως είναι ένας int, ο οποίος ταυτίζεται με το **blockDesc** του block του κάδου που προστέθηκε πιο πρόσφατα σε αυτόν. Ένα παράδειγμα της μοντελοποίησης αυτής υπάρχει στο σχήμα 1.



Σχήμα 1: Παράδειγμα μοντελοποίησης hashtable. Αν ο κάδος 1 αποτελείται από το block 7, τότε **hashtable[1] = 7**. Αν το block 7 κάποια στιγμή γεμίσει, τότε για να προστεθεί μια νέα εγγραφή στον κάδο 1 θα δημιουργηθεί ένα νέο block στο τέλος του αρχείου. Έστω ότι το νέο block έχει αριθμό—κι άρα **blockDesc**—11. Πλέον το **hashtable[1]** θα ενημερωθεί και θα αποκτήσει την τιμή 11, τον αριθμό δηλαδή του πιο πρόσφατου block του. Στο **HT_block_info** του block 11 ο αναγνωριστικός αριθμός **prevBlockDesc** θα αλλάξει από -1 και θα γίνει 7, έτσι ώστε να δείχνει στο προηγούμενο στη σειρά block. Άρα για κάθε κάδο έχουμε πρόσβαση σε όλα τα blocks του σειριακά.

- Δομή HT_block_info

Ένα block ενός αρχείου κατακερματισμού χαρακτηρίζεται από τα εξής στοιχεία:

- **int blockDesc**: Ο αναγνωριστικός αριθμός του block στην αρίθμηση των block του αρχείου κατακερματισμού.
- **int prevBlockDesc**: Ο αναγνωριστικός αριθμός του προηγούμενου block του κάδου. Αρχικοποιείται με -1 εφόσον δεν υπάρχει προηγούμενο block. Στο παράδειγμα του σχήματος 1 το **prevBlockDesc** του block 11 θα είναι ο αριθμός 7, ενώ το **prevBlockDesc** του block 7 θα είναι -1.
- **int recsNum**: Το πλήθος εγγεγραμμένων πλειάδων στο συγκεκριμένο block.

Συνάρτηση Κατακερματισμού

Η συνάρτηση κατακερματισμού που χρησιμοποιήθηκε στη συγκεκριμένη υλοποίηση είναι η $h(K) = K \% M$ όπου K είναι το κλειδί—στη συγκεκριμένη περίπτωση το `id`—, και M το πλήθος των κάδων του αρχείου κατακερματισμού.

ΕΡΓΑΣΙΑ 2

Δευτερεύον Ευρετήριο Κατακερματισμού

Συναρτήσεις

Οι παρακάτω συναρτήσεις εκμεταλλεύονται τις συναρτήσεις επιπέδου block **BF_*** για την υλοποίησή τους, προσθέτοντας ωστόσο παραπάνω λειτουργικότητα.

- **SHT_CreateSecondaryIndex**: Δημιουργεί το αρχείο δευτερεύοντος ευρετηρίου με όνομα **sfileName**, δημιουργεί το block 0 κι αρχικοποιεί τις τιμές του όσον αφορά τα **SHT_info** και **SHT_block_info**. Κάνει το block 0 **dirty** και το κάνει **uprin**. Τέλος, κλείνει το αρχείο.
- **SHT_OpenSecondaryIndex**: Ανοίγει το αρχείο δευτερεύοντος ευρετηρίου με όνομα **filename**. Ελέγχει αν το αρχείο πρόκειται για αρχείο κατακερματισμού ή όχι. Αν ναι, συνεχίζει. Αρχικοποιεί το **sht_hashtable** που θα υπάρχει στην μνήμη. Καθώς κάθε φορά που καλείται η **BF_OpenFile** το **fileDesc** αλλάζει, ενημερώνουμε κάθε φορά το **SHT_info** του block 0. Κάνουμε **dirty** κι **uprin** το block 0, κρατώντας ωστόσο το **SHT_info** στον σωρό κι επιστρέφοντάς το.
- **SHT_CloseSecondaryIndex**: Βρίσκει πόσα blocks έχει το αρχείο δευτερεύοντος ευρετηρίου. Σε ένα **for loop** κάνει το καθένα **uprin**. Κλείνει το αρχείο κι αποδεδεσμεύει την μνήμη του **SHT_info** που υπάρχει στον σωρό, καθώς και την μνήμη του **sht_hashtable**.
- **SHT_SecondaryInsertEntry**: Δημιουργεί ένα νέο **SHT_Record** από το **name** και το **blockid**. Βρίσκει τον κάδο του δευτερεύοντος ευρετηρίου στον οποίο πρέπει να καταγραφεί το **SHT_Record**, όπου σε περίπτωση λάθους επιστρέφει με τιμή -1. Αν ο κάδος δεν έχει ακόμα κάποιο κατανεμημένο σε αυτό block, τότε δημιουργεί ένα. Εισχωρεί το **SHT_Record** στο πιο πρόσφατο block του κάδου, αν χωράει σε αυτό. Αν όχι, τότε δημιουργεί ένα νέο block για τον κάδο και εισχωρεί εκεί την εγγραφή.
- **SHT_SecondaryGetAllEntries**: Η συνάρτηση επιστρέφει μία μεταβλητή **int read_blocks**. Αυτή αρχικοποιείται με -1 και ανανεώνεται όταν βρούμε ένα record με **id = value**. Αν επιστραφεί και δεν έχει αλλάξει, σημαίνει πως υπήρξε κάποιο σφάλμα. Η συγκεκριμένη συνάρτηση βρίσκει τον κάδο του δευτερεύοντος ευρετηρίου που μπορεί να περιέχει εγγραφές με **hash value = hash(name)** της εγγραφής και διατρέχει τα blocks του. Αν βρει μια τέτοια εγγραφή, τότε φορτώνει το block του **data.db** στο

οποίο δείχνει η εγγραφή. Ύστερα, το διατρέχει ώσπου να βρει την εγγραφή με όνομα `name`.

Δομή Αρχείου Κατακερματισμού

- Δομή `SHT_Record`

Αποτελεί μια εγγραφή του αρχείου δευτερεύοντος ευρετηρίου. Περιέχει:

- `char name[15]`: Το όνομα της εγγραφής. Έχει μέγιστο μήκος 15, όμοια με το `name` του `struct Record`.
- `int blockDesc`: Ο αναγνωριστικός αριθμός του block του αρχείου κατακερματισμού στο οποίο βρίσκεται η τιμή.

- Δομή `SHT_info`

Ένα αρχείο δευτερεύοντος ευρετηρίου χαρακτηρίζεται από τα εξής στοιχεία:

- `int fileDesc`: Ο αναγνωριστικός αριθμός ανοίγματος αρχείου από το επίπεδο block.
- `int lastBlockDesc`: Ο αναγνωριστικός αριθμός του τελευταίου σε αριθμό block του αρχείου δευτερεύοντος ευρετηρίου.
- `int filetype`: Ένα flag που δηλώνει τον τύπο του αρχείου. Στην περίπτωση αρχείου δευτερεύοντος ευρετηρίου έχει τιμή 3.
- `long int numBuckets`: Το πλήθος των κάδων που θα έχει το αρχείο δευτερεύοντος ευρετηρίου.
- `int *sht_hashtable`: Ένας πίνακας μεταβλητού μεγέθους σε `int`, όμοιος με τον πίνακα `hashtable` του αρχείου κατακερματισμού.

- Δομή `SHT_block_info`

Ένα block ενός αρχείου δευτερεύοντος ευρετηρίου χαρακτηρίζεται από τα εξής στοιχεία:

- `int blockDesc`: Ο αναγνωριστικός αριθμός του block στην αρίθμηση των block του αρχείου δευτερεύοντος ευρετηρίου.
- `int prevBlockDesc`: Ο αναγνωριστικός αριθμός του προηγούμενου block του κάδου. Αρχικοποιείται με -1 εφόσον δεν υπάρχει προηγούμενο block.
- `int recsNum`: Το πλήθος εγγεγραμμένων πλειάδων στο συγκεκριμένο block.

Συνάρτηση Κατακερματισμού

Η συνάρτηση κατακερματισμού του αρχείου δευτερεύοντος ευρετηρίου ορίζεται στην `SHT_Hash`. Παίρνει ως όρισμα το όνομα της εγγραφής και το πλήθος των κάδων του αρχείου. Επιστρέφει τον κάδο στον οποίο πρέπει να καταγραφεί η εγγραφή.

Ο αλγόριθμος κατακερματισμού εμπνεύστηκε εν μέρει από τον αλγόριθμο 16.2(a) του συγγράμματος [1, σ. 574], ο οποίος φαίνεται στο σχήμα 2.

Algorithm 16.2. Two simple hashing algorithms: (a) Applying the mod hash function to a character string K . (b) Collision resolution by open addressing.

```
(a)  $temp \leftarrow 1$ ;  
   for  $i \leftarrow 1$  to 20 do  $temp \leftarrow temp * code(K[i]) \bmod M$ ;  
    $hash\_address \leftarrow temp \bmod M$ ;  
(b)  $i \leftarrow hash\_address(K)$ ;  $a \leftarrow i$ ;  
   if location  $i$  is occupied  
   then begin  $i \leftarrow (i + 1) \bmod M$ ;  
       while  $(i \neq a)$  and location  $i$  is occupied  
       do  $i \leftarrow (i + 1) \bmod M$ ;  
       if  $(i = a)$  then all positions are full  
       else  $new\_hash\_address \leftarrow i$ ;  
   end;
```

Σχήμα 2: Αλγόριθμος κατακερματισμού συγγράμματος για strings.

Η υλοποίηση της συνάρτησης φαίνεται στο listing ??.

Αναφορές

- [1] Ramez Elmasri και Sham Navathe. *Fundamentals of Database Systems*. Seventh edition. Hoboken, NJ: Pearson, 2016. 1242 **pagetotals**. ISBN: 978-0-13-397077-7.